

UNIVERSITÀ DEGLI STUDI DI PADOVA

DIPARTIMENTO DI MATEMATICA

CORSO DI LAUREA IN INFORMATICA

---


# Riconoscimento e tracciamento di elementi su video ad alta risoluzione

---

*Laureando:*  
Davide LIU

*Relatore:*  
Prof. Lamberto BALLAN

*Tutor aziendale:*  
Leonardo DAL ZOVO



Anno Accademico 2018/2019

---

# Indice

<b>1</b>	<b>Introduzione</b>	<b>5</b>
1.1	Note esplicative . . . . .	5
<b>2</b>	<b>Ambiente Aziendale</b>	<b>6</b>
<b>3</b>	<b>Analisi dei problemi</b>	<b>7</b>
3.1	Tecniche di computer vision . . . . .	7
3.2	Computer vision applicata su immagini ad alta risoluzione . . . . .	8
3.3	Frammentazione dell'immagine . . . . .	9
<b>4</b>	<b>Progettazione</b>	<b>11</b>
4.1	Progettazione algoritmo per riconoscimento di elementi in un'immagine frammentata . . . . .	11
4.1.1	Scomposizione del frame originale in regioni . . . . .	11
4.1.2	Rimozione degli elementi individuati più volte all'interno delle aree di sovrapposizione . . . . .	12
4.1.3	Creazione di raggruppamenti di labels correlate . . . . .	12
4.1.4	Raggruppamenti di labels utilizzati come region proposal . . . . .	14
<b>5</b>	<b>Tecnologie</b>	<b>16</b>
5.1	Python . . . . .	16
5.2	Pycharm . . . . .	16
5.3	Tensorflow . . . . .	17
5.4	OpenCV . . . . .	17
5.5	Numpy . . . . .	17
5.6	Matplotlib . . . . .	18
5.7	Pytest . . . . .	18
<b>6</b>	<b>Sviluppo</b>	<b>19</b>
6.1	Sviluppo algoritmo per riconoscimento di elementi in un'immagine frammentata	19
6.1.1	Implementazione . . . . .	19
6.1.2	Test di integrazione . . . . .	21
<b>7</b>	<b>Risultati ottenuti</b>	<b>22</b>
7.1	Metriche utilizzate per singole immagini . . . . .	22
7.1.1	Precision . . . . .	22
7.1.2	Recall . . . . .	22

---

7.1.3	Intersection over union . . . . .	23
7.1.4	Average Precision . . . . .	23
7.1.5	Mean Average Precision . . . . .	24
<b>8</b>	<b>Glossario</b>	<b>25</b>
<b>9</b>	<b>Bibliografia</b>	<b>27</b>
<b>10</b>	<b>Appendice</b>	<b>28</b>

---

## Elenco delle tabelle

---

## Elenco delle figure

1	Logo di Studiomapp . . . . .	6
2	Esempio di un'immagine con box, categoria e probabilità per ogni elemento riconosciuto in essa . . . . .	7
3	Esempio di un frame di un video in 4K . . . . .	9
4	Logo di Python . . . . .	16
5	Logo di Tensorflow . . . . .	17
6	Esempio di intersezione e di unione . . . . .	23

---

# 1 Introduzione

La computer vision è un ambito dell'intelligenza artificiale il cui scopo è quello di insegnare alle macchine non solo a vedere un'immagine, ma anche a riconoscere gli elementi che la compongono in modo da poter interpretare il suo contenuto come farebbe il cervello di un qualsiasi essere umano. Nonostante le attuali tecniche di deep learning rendano possibile questo compito, è comunque necessaria una grande quantità di immagini e di tempo per poter allenare una rete neurale a sufficienza in modo da riuscire a riconoscere correttamente degli oggetti in un'immagine non incontrata durante il processo di allenamento.

Lo scopo del progetto di stage è stato quello di progettare e realizzare un sistema di riconoscimento e tracciamento di specifici elementi all'interno di un video ad alta risoluzione. Questo progetto ha comportato sfide e complessità aggiuntive rispetto all'analisi degli elementi presenti in una singola foto sia per il fatto che un video è composto da una sequenza di frames anziché da una singola immagine, sia per il fatto che i frames trattati erano in formato Ultra High Definition (4K) e quindi elaborare l'intero frame in una sola volta sarebbe stato troppo oneroso dal punto di vista computazionale.

Riassumendo i tre problemi principali che sono stati affrontati, in ordine sequenziale, sono i seguenti:

- Frammentazione dell'immagine;
- Tracciamento degli elementi;
- Stabilizzazione delle label degli elementi tracciati.

Ognuno dei sotto-problemi è stato analizzato a fondo, ne è stata trovata un'adeguata soluzione ed è stata applicata ai fini di realizzare un prodotto il più performante possibile.

## 1.1 Note esplicative

Allo scopo di evitare ambiguità a lettori esterni al gruppo, si specifica che all'interno del documento verranno inseriti dei termini con un carattere 'G' come pedice, questo significa che il significato inteso in quella situazione è stato inserito nel Glossario

---

## 2 Ambiente Aziendale



Figura 1: Logo di Studiomapp

STUDIOMAPP, fondata a fine 2015, è una startup innovativa con sedi a Ravenna e Roma, in Italia. Sviluppa algoritmi di intelligenza artificiale specifici per Geo-calcolo e dati geo-spaziali in modo da fornire soluzioni innovative per smart cities, mobilità, trasporti e logistica, turismo e beni culturali, immobiliare e real estate, agricoltura, territorio e gestione delle risorse naturali, adattamento ai cambiamenti climatici.

E' la prima startup dell'Emilia Romagna selezionata dall'ESA BIC Lazio, l'incubatore dell'Agenzia Spaziale Europea (ESA) ed è supportata da importanti istituzioni, acceleratori e grandi attori. Membro fondatore dal 2016 della rete Copernicus Academy, si impegna a diffondere i benefici dell'utilizzo dei dati di Osservazione della Terra per la qualità della vita dei cittadini e la competitività delle PMI.

Ha acquisito una solida esperienza nella promozione di Copernicus, il programma europeo di osservazione della Terra, nell'ecosistema Startup condividendo conoscenza e formazione. Ad oggi la società ha organizzato più di 40 eventi che hanno raggiunto più di 1000 persone che vanno dal pubblico generale, agli studenti, alle startup, ai funzionari pubblici, alle autorità locali, alle PMI.

---

## 3 Analisi dei problemi

### 3.1 Tecniche di computer vision

Per riconoscere un singolo elemento in un'immagine viene tipicamente utilizzata una Convolutional Neural Networks (CNN) allenata con grandi quantità di immagini che possono essere tranquillamente reperite in rete già raggruppate in datasets come ad esempio ImageNet. La vera sfida salta fuori non appena ci troviamo a dover identificare nella stessa immagine diversi oggetti appartenenti a categorie diverse, di differenti dimensioni e posizioni e talvolta anche sovrapposti. Questa situazione è molto comune quando ci troviamo ad osservare qualsiasi foto rappresentante il mondo reale. Il risultato ottimale sarebbe quindi di avere una label di dimensioni corrette per ogni oggetto identificato mostrando anche la categoria di appartenenza dell'elemento e la probabilità che la classificazione sia effettivamente quella corretta.




Figura 2: Esempio di un'immagine con box, categoria e probabilità per ogni elemento riconosciuto in essa

Il modo più semplice per andare incontro a questo problema è quello di utilizzare una R-CNN (Regional Convolutional Neural Network) la quale tramite un algoritmo greedy chiamato Selective Search estrae delle regioni di interesse nelle quali è probabile che vi sia presente un oggetto. Queste regioni vengono poi date singolarmente in input ad una normale CNN la quale ha il compito di estrarne le caratteristiche principali per poi utilizzare una Support Vector Machine (SVM) presente nell'ultimo strato della CNN per rilevare la presenza di un oggetto ed eventualmente classificarlo. Questo tipo di soluzione presenta il difetto di richiedere molto tempo durante l'operazione di ricerca delle regioni di interesse.



---

La versione più avanzata della R-CNN ed attualmente in uso nei sistemi di computer vision attuali è chiamata Faster R-CNN e risolve il bottleneck della sua antecedente sostituendo la Selective Search con una Region Proposal Network (RPN). Essa prende come input un'immagine di qualsiasi dimensione e restituisce come output un insieme di rettangoli associati ad una probabilità che esse contengano un oggetto o meno. Tramite una CNN viene prima costruita la mappa delle caratteristiche più significative dell'immagine, in seguito viene utilizzata una sliding window per scorrere la mappa delle caratteristiche e darle in input a due fully-connected layers dei quali uno serve per individuare le coordinate del box dell'oggetto<sup>1</sup> mentre l'altro serve per ritornare la probabilità che nel box vi sia effettivamente un oggetto<sup>2</sup>. Infine queste regioni vengono passate ad una Fast R-CNN che avrà come al solito il compito di riconoscere e classificare l'oggetto.

### 3.2 Computer vision applicata su immagini ad alta risoluzione

Sebbene sul web sia abbastanza facile reperire grandi quantità di immagini con cui allenare i propri modelli, tuttavia la maggior parte di questi datasets contiene solamente immagini a bassa risoluzione ed è difficile trovare in rete grandi datasets di immagini o video in 4K. Inoltre, la maggior parte dei modelli sono stati progettati per lavorare su immagini a bassa risoluzione (tra i 200 e i 600 pixels) sia per il fatto che una bassa risoluzione è comunque sufficiente per riconoscere e classificare un elemento, sia perchè è più efficiente lavorare su immagini di bassa qualità che su immagini in con una risoluzione molto alta.

Lo svantaggio che questo comporta è che nelle immagini in bassa risoluzione si perdono molti dei dettagli che invece potrebbero essere catturati da un'immagine o da un video ad alta risoluzione. In aggiunta, i video in 4K o addirittura 8K sono al giorno d'oggi sempre più diffusi perciò anche gli attuali modelli dovranno prima o poi adattarsi per trattare efficacemente immagini di tali risoluzioni. Nella figura sottostante si può vedere un esempio di un frame in alta risoluzione nel quale, diminuendone le dimensioni e perdendo quindi qualità, non sarebbe stato possibile riconoscere alcune delle persone individuate nel frame.

---

<sup>1</sup>Box-regression layer

<sup>2</sup>Box-classification layer



Figura 3: Esempio di un frame di un video in 4K

### 3.3 Frammentazione dell'immagine

Un'immagine in 4K ha una risoluzione di  $3840 \times 2160$  pixels per un totale di 8294400 di pixels. Una rete neurale in grado di ricevere un input così corposo dovrebbe allenare un numero molto elevato di parametri risultando così in un processo molto lungo e dispendioso tanto che molti dei modelli attuali effettuano un ridimensionamento dell'immagine per adattarla al meglio al loro input. L'idea per aggirare il problema è quella di frammentare l'immagine in diverse sotto-immagini di dimensioni minori e quindi gestibili efficacemente da una singola rete neurale. Questa particolare strategia è chiamata frammentazione dell'immagine e risulta essere molto utile in quanto permette di analizzare un'immagine ad alta risoluzione scomponendola in frammenti di dimensioni minori anziché gestirla nella sua interezza.

(FIGURA) Tuttavia questo procedimento non è esente da difficoltà. Nel caso in cui un oggetto dovesse trovarsi su più regioni diverse, esso potrebbe venire identificato più volte o addirittura essere riconosciuto ogni volta come se fosse un oggetto appartenente ad una categoria diversa.

Un primo approccio per risolvere questo problema è quello di porre maggiore attenzione alle labels degli oggetti posizionati in prossimità dei confini delle regioni in quanto con molta probabilità è possibile che l'oggetto continui invece nella regione adiacente piuttosto che essere interamente contenuto nella regione esaminata. Se è quindi presente una label anche in una regione adiacente si passa allora alla verifica che le due labels possano effettivamente appartenere allo stesso elemento. Per fare ciò bisogna assicurarsi che le due labels siano compatibili sia in termini di categoria che di posizione entro una certa soglia ed in caso

---

affermativo fonderle in una sola label contenente l'oggetto intero.

Un'altra soluzione esaminata è quella di suddividere l'immagine intera in regioni con sovrapposizione. In questo modo un elemento contenuto all'interno di un'area di sovrapposizione tra più regioni genererebbe due o più labels quasi completamente sovrapposte. Il problema può essere facilmente gestito con un algoritmo di Non-Maximum Suppression, il quale, per ogni insieme di labels parzialmente sovrapposte e con stessa categoria, tende ad eliminare le labels con probabilità minore tenendo valida solo quella con probabilità massima. Tuttavia caso più insidioso ed allo stesso tempo più frequente avviene quando due o più labels non solo hanno un'intersezione dentro un'area di sovrapposizione ma la loro box si estende anche al di fuori di esse. E' proprio per far fronte a questo problema che è stato ideato ed implementato un algoritmo il quale verrà descritto nella *sezione 4.1*. (Figura)

---

## 4 Progettazione

### 4.1 Progettazione algoritmo per riconoscimento di elementi in un'immagine frammentata

Per quanto riguarda il problema della frammentazione dei frames in 4K è stato individuato un apposito algoritmo in grado di effettuare il riconoscimento degli oggetti nei frames presenti in un video senza doverli ridimensionare ma utilizzando la tecnica della frammentazione dell'immagine.

#### 4.1.1 Scomposizione del frame originale in regioni

Un frame in 4K viene quindi scomposto in una matrice di  $R \times C$  sotto-immagini chiamate  $regioni_G$  in modo tale che ogni regione sia efficacemente analizzabile da un modello come Faster R-CNN. Per facilitare l'operazione di riconoscimento degli elementi da parte della rete, ogni regione si sovrappone leggermente con le sue regioni adiacenti. Per definire la quantità di pixels da coinvolgere nella sovrapposizione viene definito uno  $stride_G$  che indica quanti pixels della regione tralasciare, sia in verticale che in orizzontale, prima che cominci quella successiva, ovviamente lo stride deve essere minore della larghezza di una regione. Una Faster R-CNN dopo aver elaborato singolarmente ogni regione come se fosse una singola immagine darà in output una lista di  $labels_G$  con le seguenti caratteristiche:

- **(max-x, max-y)**: coordinate del vertice in alto a sinistra del rettangolo rappresentante la label dell'oggetto riconosciuto;
- **(min-x, min-y)**: coordinate del vertice in basso a destra del rettangolo rappresentante la label dell'oggetto riconosciuto;
- **Categoria $_G$**  : è un numero naturale che indica la categoria di appartenenza dell'elemento individuato;
- **Score $_G$**  : rappresenta la misura di probabilità che la classificazione ottenuta sia effettivamente quella corretta.

Successivamente viene aggiustata la posizione delle labels individuate in modo da traslarle nella loro posizione corretta all'interno dell'immagine originale non frammentata. Questo viene fatto aggiungendo un adeguato offset alle coordinate dei vertici dei box delle labels sulla base della loro regione di appartenenza.

---

#### 4.1.2 Rimozione degli elementi individuati più volte all'interno delle aree di sovrapposizione

A causa della presenza delle aree di sovrapposizione dovute alla struttura delle regioni, gli elementi giacenti in queste particolari zone del frame verranno individuati tante volte quante sono le regioni che si sovrappongono in quella determinata area. Per eliminare le copie duplicate e tenerne solo una viene utilizzato un algoritmo chiamato Average Non-Max Suppression (ANMS) che è una variante del Non-Max Suppression tipicamente utilizzato dai modelli di visione artificiale. Invece che tenere la label con lo score maggiore ed eliminare tutte le altre, come box viene calcolato il box che deriva dalla media dei box di tutte labels e lo score viene calcolato come la media dei loro score. Questo metodo è fondato sul ragionamento che non bisognerebbe buttare via delle informazioni già possedute ma piuttosto riutilizzarle per scoprire qualcosa di nuovo. Per esempio ad uno stesso elemento visualizzato dentro due sezioni differenti di un' immagine potrebbero venirgli assegnati due score diversi. Mentre NMS conserverebbe solo il valore più alto tra i due, ANMS li utilizzerebbe entrambi per ottenere un valore ancora più affidabile aumentando quindi la veridicità della classificazione.

#### 4.1.3 Creazione di raggruppamenti di labels correlate

A questo punto tutti gli elementi sono stati individuati e classificati ma rimane comunque il problema che, a causa della precedente scomposizione, gli oggetti situati all'interno delle aree di sovrapposizione risulterebbero individuati due o più volte. Come si può vedere in figX, questo numero varia in base al numero di regioni sulle quali giace l'oggetto. Il secondo problema è che due elementi *vicini*<sup>3</sup>, anche se classificati nella stessa categoria, non è detto che necessariamente debbano rappresentare lo stesso elemento. Un esempio di questo caso lo si può notare in figX. Un caso ancora peggiore è quello mostrato in figX dove non solo l'elemento è situato su più regioni differenti ma sussiste anche il problema che ogni parte dell'elemento verrebbe classificata in modo diverso a causa della loro ambiguità. Infine, la figX mostra un oggetto che si distribuisce su molte regioni ed ogni sua label presenta dimensioni diverse. La soluzione individuata consiste nel raggruppare labels correlate tra loro in insiemi di labels dette raggruppamenti<sub>G</sub> per poi racchiuderli in una label che identifichi l'elemento rappresentato dal raggruppamento. Due labels sono in correlazione tra di loro se soddisfano una condizione di correlazione sotto riportata.

**Condizione di correlazione:** Per effettuare un corretto raggruppamento delle labels viene anche tenuta in considerazione la categoria a loro associata tramite la classificazione insieme allo score assegnato. Per definire il risultato della condizione è inoltre necessario stabilire una

---

<sup>3</sup>Due label sono considerate vicine se sono intersecate tra di loro ed intersecano lo stesso confine di regione

---

soglia<sub>G</sub> di probabilità per considerare una label come affidabile o meno. Di seguito vengono riportati i vari casi per decidere se la condizione è vera o falsa.

- **True:** Le due labels hanno la stessa categoria ed entrambe con score uguale o maggiore della soglia;
- **True:** Le due labels hanno la stessa categoria ma almeno una delle due ha score minore della soglia;
- **True:** Le due labels hanno categoria diversa ma almeno una delle due ha score minore della soglia;
- **False:** Le due labels hanno categoria diversa ed entrambe con score uguale o maggiore della soglia;

Prima di cominciare con il raggruppamento, vengono inizialmente individuate tutte le labels che intersecano i confini di regioni causati dalle aree di sovrapposizione o che non distino più di un fissato numero di pixels, detto overlap<sub>G</sub>, da esse. L'overlap viene definito in quanto anche se nell'immagine reale un oggetto interseca un confine di regione è possibile che a causa di errori di imprecisione del modello, il box della label risulti leggermente distaccato dalla linea che rappresenta il confine. E' quindi possibile ovviare a questo problema aumentando lo spessore del confine di tanti pixels quanti indicati nell'overlap. Per lo stesso motivo precedente, ai fini di controllare se una label interseca un' altra entità o meno viene anche tenuta in considerazione una tolleranza<sub>G</sub> che indica quanto il box della label può essere distante da quell'entità affinché questa venga comunque considerata come intersecata. Per creare i raggruppamenti di labels è stato ideato il seguente algoritmo:

1. Vengono tenute solo le labels che intersecano almeno un confine di regione e sono inizializzate come *non controllate*;
2. Viene selezionata una label qualsiasi *non controllata* e la si imposta come *controllata*;
3. Per ogni label *controllata* ma non ancora *Raggruppata* controlla se ci sono altre labels *non controllate* che rispettino ognuna delle seguenti condizioni:
  - Devono essere *vicine* o distanti entro la tolleranza<sub>G</sub> fissata;
  - Devono rispettare la *condizione di correlazione*;
  - La loro box non deve intersecare una regione al di fuori delle aree di sovrapposizione che sia già intersecata da una qualsiasi label *controllata*<sup>4</sup>;

---

<sup>4</sup>Questo perché se due labels sono state individuate come elementi distinti all'interno di una regione allora è probabile che lo siano anche nell'immagine intera in quanto viene supposto che un modello non commetta errori di riconoscimento

- 
- La posizione delle loro aree deve essere compatibile entro una certa soglia ovvero che, i lati lungo il quale le due labels vengono unite siano tali che la differenza tra quello maggiore e quello minore sia inferiore ad una certa soglia che può essere sia definita come proporzione rispetto ad uno dei due lati oppure un valore in pixels.
4. Le labels così trovate diventano a loro volta *controllate*;
  5. Si ripetono i punti 3 e 4 fino a che non sia più possibile trovare ulteriori labels;
  6. Tutte le label *controllate* vengono ora classificate come *raggruppate* e viene assegnato un numero progressivo ad ogni label *raggruppata* in modo da identificarne il gruppo di appartenenza;
  7. Si ripetono i punti da 2 a 6 fino a che tutte le labels non vengano raggruppate. L'algoritmo in questo modo termina sempre ed è possibile che un raggruppamento comprenda una sola label.

E' da notare che labels intersecanti ma interamente comprese in una sola regione non sono motivo di interesse in quanto l'algoritmo di Non-Maximum Suppression utilizzato dalla rete in fase di post-processing ci assicura che labels intersecanti individuino elementi diversi. In seguito bisogna trasformare ogni raggruppamento in una nuova label che racchiuda tutte le labels che lo compongono. Per fare questo vengono esaminate le coordinate di ogni vertice di tutte le labels di un raggruppamento in modo tale da trovare quattro nuovi vertici di un rettangolo che soddisfi i requisiti sopra discussi. Il nuovo box così creato andrà a sostituire le labels del rispettivo raggruppamento e per deciderne la categoria e lo score viene applicata una **regola di classificazione**: categoria e score assegnati saranno pari alla categoria e allo score posseduti dalla label con score maggiore.

A questo punto l'algoritmo può dirsi concluso ed è in grado di riconoscere gli elementi in un'immagine in 4K con un'accuratezza accettabile e buona velocità. Tuttavia in casi particolari come quello mostrato in figura figX l'algoritmo commetterebbe un errore di classificazione in quanto individuerrebbe tre elementi distinti con una sola label comune.

#### 4.1.4 Raggruppamenti di labels utilizzati come region proposal

Un ulteriore miglioramento dell'algoritmo viene ottenuto utilizzando le labels ottenute dal procedimento descritto in precedenza come nuove regioni sulle quali applicare nuovamente Faster R-CNN per identificare nuovamente gli elementi contenuti nella regione ma con maggiore precisione in quanto questa volta l'area non verrà affetta da problemi di frammentazione dando quindi la possibilità alla rete di esaminare l'oggetto per intero. La regione viene prima

---

inizializzata rimuovendo la sua label e poi ripopolata con le nuove labels identificate dalla rete. Il primo problema che salta fuori è che durante questo procedimento la rete identificherà nuovamente anche quegli elementi che casualmente si trovavano dentro la regione coinvolta ma che erano già stati trovati anche in precedenza. Tuttavia questo problema viene tranquillamente risolto applicando un algoritmo di Average Non-Max Suppression, utilizzato già in precedenza, per eliminare oggetti quasi completamente sovrapposti. Il secondo problema riguarda ancora gli oggetti che stanno a cavallo tra la regione interessata e l'immagine originale, questa volta però, avendoli già individuati nella loro interezza durante la prima fase è quindi solamente necessario fondere la nuova label con quella già trovata in precedenza. Un caso particolare lo si ha quando la regione in esame risulti essere così estesa da vanificare i vantaggi ottenuti dalla frammentazione. Per far fronte a questo problema basta ridimensionare l'area coinvolta fino a portarla ad avere dimensioni gestibili da un modello. In questo caso la perdita di risoluzione e quindi di dettagli non comporterebbe un grave problema in quanto gli elementi visibili solo grazie all'alta definizione sono già stati individuati nella fase precedente. Nel caso in cui dovessero venire nuovamente identificati verrebbero gestiti dall'ANMS per ottenerne una migliore approssimazione. Questa funzionalità permette di migliorare l'accuratezza quando si vogliono identificare oggetti che si estendono su due o più regioni o per migliorare il riconoscimento di gruppi di elementi sovrapposti e molto vicini tra loro in prossimità di un confine.



---

## 5 Tecnologie

### 5.1 Python

Il linguaggio di programmazione utilizzato per perseguire gli obiettivi del progetto è stato Python<sup>v3.7</sup>, si tratta di un linguaggio di programmazione di alto livello il cui obiettivo è quello di facilitare la leggibilità del codice ed adattarsi a diversi paradigmi di programmazione come quello procedurale, ad oggetti e funzionale. La motivazione per la scelta dell'utilizzo di questo linguaggio, oltre alla sua semplicità, è per il suo supporto di numeri frameworks e moduli relativi al deep learning e alla computer vision tra i quali Tensorflow e OpenCV. Qualsiasi modulo aggiuntiva può essere semplicemente installata eseguendo il comando:

```
pip install nome_modulo
```

Per lanciare un programma viene utilizzato il comando:

```
python nome_file.py
```

Altri moduli che sono stati utilizzati comprendono Numpy, Matplotlib e Pytest.



Figura 4: Logo di Python

### 5.2 Pycharm

Pycharm è un IDE per programmare in Python sviluppato da JetBrains. Le sue caratteristiche più importanti includono:

- Un sistema intelligente di completamento automatico del codice;
- Analisi statica del codice eseguita a tempo di esecuzione;
- Individuazione e risoluzione veloce degli errori tramite proposte di correzione;
- Possibilità di lavorare in un ambiente di sviluppo virtuale dove per ogni progetto vengono installate solamente le proprie dipendenze e i propri moduli.

---

### 5.3 Tensorflow

Tensorflow è un framework gratuito e open-source per lo sviluppo e l'allenamento di modelli di machine learning come le reti neurali. Ha la particolarità che i dati vengono gestiti attraverso dei grafi computazionali dove i nodi rappresentano delle operazioni matematiche da eseguire e gli archi rappresentano degli array multidimensionali contenenti i dati sui quali svolgere le operazioni (tensori). La sua architettura permette di svolgere le operazioni sia usando la CPUs che le GPUs in modo da eseguire operazioni con alto livello di parallelismo.

NON ANCORA USATO



Figura 5: Logo di Tensorflow

### 5.4 OpenCV

OpenCV è una libreria open.source orientata allo sviluppo di applicazioni di computer vision in tempo reale. E' stata scritta originariamente in C++ ma offre anche il supporto ad altri linguaggi di programmazione come Python.

NON ANCORA USATO

### 5.5 Numpy

Numpy è un modulo di Python che fornisce il supporto per la gestione di matrici e array multidimensionali di grandi dimensioni. Dispone anche di una vasta collezione funzioni matematiche per lavorare ad alto livello su di essi. Viene spesso utilizzato per operare su grandi quantità di dati in modo rapido ed efficiente.

---

## 5.6 Matplotlib

Matplotlib è una libreria grafica sviluppata per Python impiegata principalmente per disegnare grafici o altre figure con lo scopo di rappresentare dei dati utilizzando il minor numero di righe di codice possibile. In fase di allenamento di una rete neurale viene spesso usato per mostrare l'andamento della variazione dell'errore e dell'accuratezza.

## 5.7 Pytest

Pytest è un framework per Python che permettere di scrivere dei test per testare il codice permettendone la loro esecuzione in modo automatico. Per installarlo viene utilizzato il comando:

```
pip install pytest
```

mentre per lanciaarne l'esecuzione viene usato il comando:

```
pytest nome_file
```

Per convenzione il file contenente i test relativi ad un solo modulo è stato chiamato "nome\_modulo\_test.py" dove "nome\_modulo.py" è il modulo ad esso associato. I metodi che eseguono un test devono iniziare con "test\_", in caso contrario non verranno riconosciuti come tali e la loro esecuzione non verrà lanciata. Sono stati implementati dei test di unità per tutte le funzioni più complesse o critiche in modo da verificarne il corretto funzionamento. Sono anche stati sviluppati dei test di integrazione per ogni algoritmo implementato in modo da assicurarsi del loro corretto funzionamento. Per valutare l'esecuzione dell'intero sistema sono invece state utilizzate delle metriche per misurare la bontà del risultato in quanto i test di sistema non sarebbero stati adatti per misurare un risultato non deterministico come il riconoscimento di oggetti.

---

## 6 Sviluppo

### 6.1 Sviluppo algoritmo per riconoscimento di elementi in un'immagine frammentata

Al fine di implementare l'algoritmo è stata creata una libreria contenente numerose funzioni per lavorare con le labels ritornate dal modello come per esempio ottenerne la posizione o controllare le loro intersezioni con altre entità. Una label è composta da un array formato da quattro numeri interi caratterizzanti il vertice in alto a sinistra e quello in basso a destra del bounding box, un intero per rappresentare la categoria dell'elemento ed infine un numero decimale compreso tra 1 e 0 per indicarne lo score. Viene data la possibilità all'utente di ridefinire la propria *condizione di correlazione* e la *regola di classificazione* passandole come parametro direttamente nella funzione. Altri parametri passabili includono: le labels, le dimensioni delle regioni e dello stride e la quantità di overlap, sia in verticale che in orizzontale, e di tolleranza in pixels. Alla fine l'algoritmo ritornerà una lista di tutte le labels presenti nell'immagine.

Nella seguente sezione ne viene riportata una sua implementazione.

#### 6.1.1 Implementazione

```
1 from faster_nms import faster_nms
2 import numpy as np
3 import labels as lb
4
5 def process_image_labels(boxes, region_size=(300, 300), stride_size=(270, 270),
6   , overlap=(0, 0), tol=0, condition=None, find_category=None):
7     if condition is None:
8         condition = lb.condition
9     if find_category is None:
10         find_category = lb.find_category
11
12     w, h = lb.img_dim_from_boxes(boxes)
13     regions = lb.generate_regions(w, h, region_size, stride_size)
14     boxes = faster_nms(boxes, overlapThresh=0.8)
15
16     # Keeps only the labels intersecting one or more region edges
17     lb.get_intersect_edges_labels(boxes, regions, tol, overlap)
18     # All labels are set as not-checked and not-grouped
19     checked = np.zeros((np.ma.size(ne_boxes, 0)))
20     grouped = np.ones((np.ma.size(ne_boxes, 0))) * (-1)
21     n_group = 0
22     for i in range(len(ne_boxes)):
```

---

```

22     # Select a label and sets it as checked
23     if not checked[i]:
24         checked[i] = True
25         while True:
26             found = 0
27             # If a label is checked then it means it is not-grouped
28             for j in range(len(ne_boxes)):
29                 if checked[j] and grouped[j] == -1:
30                     for k in range(len(ne_boxes)):
31                         if not checked[k] and lb.intersection(ne_boxes[j,
: ], ne_boxes[k, :], tol) and condition(ne_boxes[j, :], ne_boxes[k, :]) and
lb.intersect_common_edge(ne_boxes[j, :], ne_boxes[k, :], regions, tol,
overlap) and lb.matched(ne_boxes[j, :], ne_boxes[k, :]) and not lb.
belong_same_region_strict_group(ne_boxes[k, :], checked_boxes, regions,
tol):
32                                     # The new found label is set as checked
33                                     checked[k] = True
34                                     found += 1
35             # The cycle is repeated until no new labels can be found
36             if found == 0:
37                 break
38             # All the checked labels are set as grouped and is them assigned a
number with the purpose of identify their group ID
39             for j in range(len(ne_boxes)):
40                 if checked[j] and grouped[j] == -1:
41                     grouped[j] = n_group
42             n_group += 1
43     # Now we have that each label only belongs to a single group
44
45     # Now that we have grouped the labels each group is merged into a label
containing all of them
46     new_boxes = np.zeros((0, 6))
47     for i in range(n_group):
48         # For each group
49         v = np.zeros((0, 6))
50         count = 0
51         for j in range(len(ne_boxes)):
52             if grouped[j] == i:
53                 v = np.append(v, ne_boxes[j, :])
54                 count += 1
55         v = v.reshape(count, 6)
56     # Find the coordinates of the labels containing the whole group
57     xx1 = np.amin(v, axis=0)[0]
58     yy1 = np.amin(v, axis=0)[1]
59     xx2 = np.amax(v, axis=0)[2]

```

---

---

```
60     yy2 = np.amax(v, axis=0)[3]
61     # find_category can be redefined by the user
62     categories, scores = find_category(v)
63     for j in range(len(categories)):
64         new_boxes = np.append(new_boxes, np.array([xx1, yy1, xx2, yy2,
categories[j], scores[j]]))
65     # new_boxes are the labels resulting from grouping algorithm
66     new_boxes = new_boxes.reshape(int(len(new_boxes) / 6), 6)
67
68     # The algorithm is over now thus we can return the results
69     final_boxes = np.append(new_boxes, old_boxes, 0)
70
71     return final_boxes
```

Listing 1: Python example

### 6.1.2 Test di integrazione

Al fine di verificarne la correttezza sono stati implementati 80 test di integrazione. Essi hanno il compito di testare l'algoritmo su diverse disposizioni e quantità di labels impostando i parametri con differenti valori in modo tale da riconoscerne il maggior numero di errori possibile. Sono state testate in totale sei disposizioni di labels con due diversi valori di overlap, tolleranza, stride e dimensione delle regioni arrivando ad un totale 80 test passati tutti con esito positivo.

---

## 7 Risultati ottenuti

### 7.1 Metriche utilizzate per singole immagini

Nell'ambito della computer vision vengono tipicamente utilizzate due tipi di metriche per misurare due diverse proprietà:

- Corretta determinazione della posizione degli oggetti;
- Rilevamento l'esistenza degli oggetti nell'immagine e la loro corretta classificazione.

Le metriche utilizzate per misurare la bontà dei risultati del progetto sono AP (Average Precision) e mAp (mean Average Precision) le quali misurano la seconda proprietà sopra elencata. Prima di iniziare a descrivere le due metriche è necessario definire tre concetti che saranno poi coinvolti per il calcolo dei valori delle metriche.

#### 7.1.1 Precision

La precision misura l'accuratezza delle classificazioni ed indica la percentuale di classificazioni corrette sulla base di quelle totali e viene calcolata come:

$$precision = \frac{TP}{TP + FP}$$

Dove TP (True Positives) è il numero di classificazioni corrette e FP (False Positives) è il numero di classificazioni errate. E' da sottolineare che se uno stesso elemento viene individuato più di una volta, solo la prima volta conterà come TP mentre il resto delle volte conterà come FP. Questa metrica fornisce un'idea sulla correttezza dei risultati.

#### 7.1.2 Recall

La recall misura quanti oggetti sono stati individuati e classificati correttamente sulla base degli oggetti totali, viene calcolata come:

$$precision = \frac{TP}{TP + FN}$$

Dove TP (True Positives) è sempre il numero di classificazioni corrette mentre FN (False Negatives) è il numero di di oggetti che non sono stati individuati ma che se sarebbero stato corretto individuare. Questa metrica fornisce un'idea sulla completezza dei risultati.

---

### 7.1.3 Intersection over union

L'intersection over union (IoU) misura il grado di sovrapposizione tra due aree e viene usato per misurare il grado di sovrapposizione tra la box dell'oggetto individuato e la box dell'oggetto reale. Viene calcolata come:

$$IoU = \frac{AI}{AU}$$

Dove AI (Area dell'Intersezione) corrisponde all'area dell'intersezione tra le due box e AU (Area dell'Unione) corrisponde all'area dell'unione tra le due box. Una label per essere considerata come corretta deve avere un valore di IoU maggiore di una soglia stabilita (per esempio 0.5).




Figura 6: Esempio di intersezione e di unione

### 7.1.4 Average Precision

Una delle due metriche utilizzate è l'average precision (AP) e per calcolarla si fa la media delle precisioni di undici diversi valori di recall equamente distribuiti. Questa metrica viene applicata ad una sola categoria di elementi e viene calcolata tramite la seguente formula:

$$AP = \frac{1}{11} \sum_{Recall_i} Precision(Recall_i)$$

Dove  $i=[0, 0.1, 0.2, \dots, 1.0]$  in quanto  $0 < recall < 1$ . Inoltre la precisione di uno specifico valore di recall viene calcolata nel seguente modo:

$$Precision(Recall_i) = \max Precision(Recall_j) \quad \text{and} \quad j \geq i$$

L'AP è un valore che riassume la forma della curva precision/recall per una data categoria.



---

### 7.1.5 Mean Average Precision

La mean average precision (mAP) è la media delle AP di tutte le categorie calcolata su diverse soglie di IoU:

$$mAP_{IoU=x\%} = \frac{1}{n} \sum_{i=0}^n AP_i$$

Dove  $i$  è il numero totale di categorie sulle quali è stata calcolata la propria AP e  $x$  rappresenta diverse soglie di IoU.

---

## 8 Glossario

### B

**Box** E' un rettangolo che identifica il perimetro entro quale l'oggetto riconosciuto si trova.

### C

**Categoria** L'obiettivo della classificazione è quello di assegnare all'oggetto individuato la sua categoria di appartenenza.

### L

**Label** Etichetta che viene data ad ogni elemento riconosciuto e ne indica la categoria di appartenenza, una bounding box ed uno score.

### O

**Overlap** L'overlap indica lo spessore in pixels dei confini delle regioni. E' usato per sapere se un' entità interseca un confine o meno.

### R

**Raggruppamento** Insieme di labels correlate tra loro tale che da una qualsiasi label del gruppo sia possibile raggiungere qualsiasi altra label dello stesso insieme passando solo per label *vicine* <sup>5</sup>.

**Regione** Una sezione di un'immagine con un'area di dimensione minore dell'area dell'immagine originale.

### S

**Score** La probabilità che la categoria associata all'elemento riconosciuto sia quella corretta.

---

<sup>5</sup>Due label sono considerate vicine se sono intersecate tra di loro ed intersecano lo stesso confine di regione

---

**Soglia** E' il valore che lo score di una label deve eguagliare o superare per essere considerata affidabile.

**Stride** E' un attributo da tenere conto in fase di frammentazione di un'immagine ed indica quanti pixels della regione tralasciare, sia in verticale che in orizzontale, prima che cominci quella successiva. Lo stride orizzontale può avere dimensione diversa da quello verticale. La sua applicazione ha come scopo quello di creare delle zone di sovrapposizione tra le varie regioni.

## T

**Tolleranza** La distanza in pixels per la quale una label può discostare da una zona di interesse per cui sia ancora considerata essere intersecata con la zona di interesse.

---

## 9 Bibliografia

### Riferimenti bibliografici

- [1] Sito web dell'azienda Studiomapp.  
<https://www.studiomapp.com/en/>
- [2] Alex Krizhevsky, Ilya Sutskever, Geoffrey E. Hinton. *ImageNet Classification with Deep Convolutional Neural Networks*. University of Toronto.
- [3] Ross Girshick, Jeff Donahue, Trevor Darrell, Jitendra Malik. *Rich feature hierarchies for accurate object detection and semantic segmentation*. UC Berkeley.
- [4] Shaoqing Ren, Kaiming He, Ross Girshick, Jian Sun. *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*. Microsoft Research.
- [5] Vít Ruzicka, Franz Franchetti. *Fast and accurate object detection in high resolution 4K and 8K video using GPUs*. Carnegie Mellon University.
- [6] Imagenet database.  
<http://www.image-net.org/>
- [7] Guida all'utilizzo del framework Tensorflow.  
<https://www.tensorflow.org/>
- [8] Guida all'utilizzo del modulo matplotlib.  
<https://matplotlib.org/>
- [9] Guida all'utilizzo del modulo numpy.  
<https://www.numpy.org/>
- [10] Guida all'utilizzo del modulo OpenCV.  
<https://www.pyimagesearch.com/>
- [11] Studio delle metriche.  
[https://medium.com/@jonathan\\_hui/map-mean-average-precision-for-object-detection-45c](https://medium.com/@jonathan_hui/map-mean-average-precision-for-object-detection-45c)

---

## 10 Appendice